프로젝트 M

시연 학습

Learning from Demonstrations

사람이 상자 밀기를 직접 플레이해 녹화하고, 그 기록을 섞어 처음 성공까지의 시간을 줄인다.

난이도 ★★★ · 핵심 개념: BC · GAIL

ML-Agents 강화학습 프로젝트 · 개발 기획서



사람의 키보드 → 녹화 → 학습 → 에이전트

목차

게임을 먼저 설계하고, 그 게임을 강화학습 문제로 옮긴다

01 **프로젝트 개요** — 무엇을 만드는가 — 한 장 요약

02 **게임 디자인** — 컨셉 · 플레이 방식 · 등장 요소 · 사람 조작

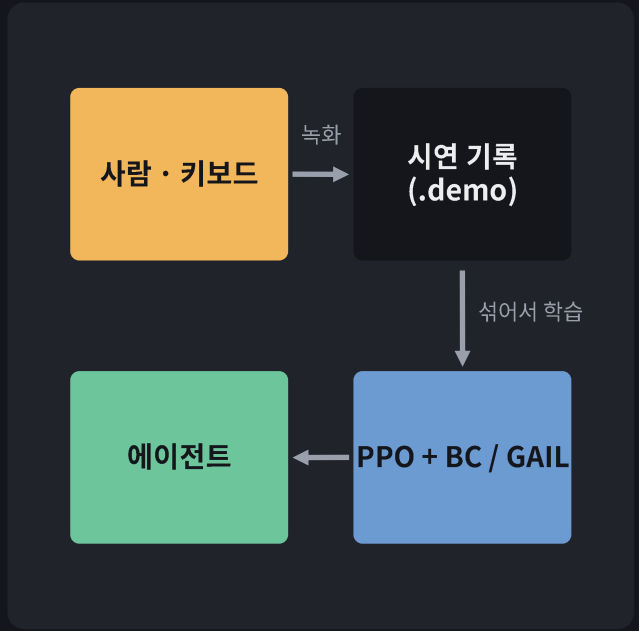
03 **강화학습 설계** — 게임을 학습 문제로 — 관측 · 행동 · 보상 · 에피소드

04 **학습 계획** — 학습 환경 · 개발 단계 · 예상 문제와 대응

프로젝트 개요

사람이 상자 밀기를 직접 플레이해 녹화하고, 그 기록을 섞어 처음 성공까지의 시간을 줄인다.

장르	물리 퍼즐 (F 상자 밀기 + 사람 시연)
플레이어	상자를 미는 공 — 처음엔 사람, 나중엔 에이전트
목표	상자를 골에 넣는다 — 시연 없이보다 빨리 배우기
실패	1500 스텝 안에 못 넣음
학습 대상	사람의 시범을 출발점으로 삼아 더 잘하기
새 개념	Demonstration Recorder · BC · GAIL
예상 학습	바탕 과제와 같거나 짧게 (예상치)



게임 컨셉

이 게임은 무엇이고, 무엇이 잘한 플레이인가

사람이 먼저 보여 주고, 에이전트는 그 시범에서 출발해 스스로 다듬는다

핵심 재미

내 플레이가 AI 의 교과서가 된다

잘한 시연

같은 상황에서 늘 같은 방식 — 상자 뒤로 돌아가 민다

나쁜 시연

들쭉날쭉한 조작 — AI 가 습관까지 따라 한다

플레이 방식

한 판은 이렇게 흘러간다

사람 플레이
Heuristic으로 성공 20판

→

녹화
.demo 파일 저장

→

학습
PPO + BC 또는 GAIL

→

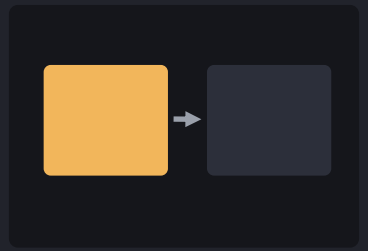
에이전트 플레이
시범보다 잘하기

한 판 예시



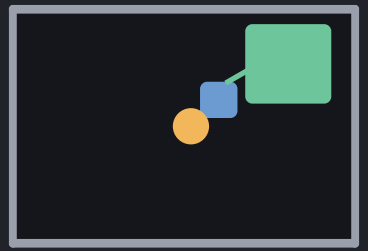
① 사람이 플레이

키보드로 성공 판을 녹화



② 시연 기록

관측과 행동의 쌍이 파일로



③ 따라 하며 시작

BC — 사람의 선택을 흉내



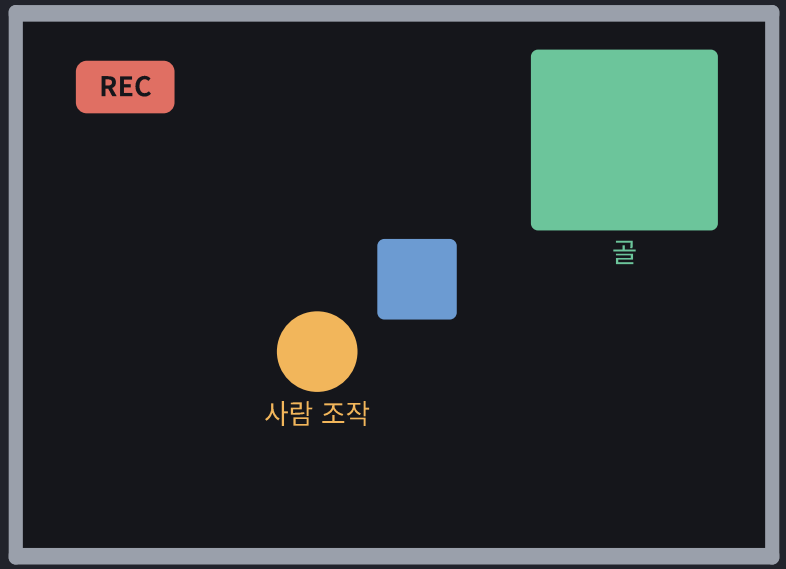
④ 스스로 다듬기

PPO 가 시범보다 낫게 만든다

플레이 과정 ① 사람이 플레이

키보드로 성공 판을 녹화

① 사람이 플레이 | ② 시연 기록 | ③ 따라 하며 시작 | ④ 스스로 다듬기



게임에서 일어나는 일

- Behavior Type = Heuristic Only
- Demonstration Recorder 켜기
- 상자를 골에 넣는 판 20개

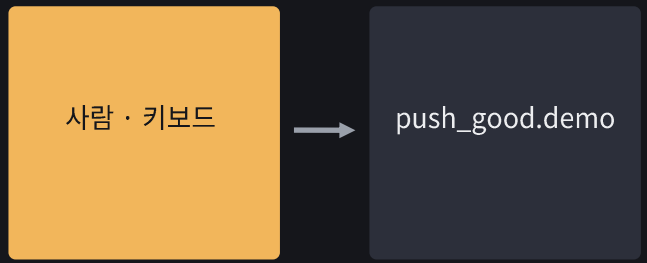
플레이어의 판단 "늘 같은 방식으로 밀자"

관측	행동	보상
관측 8칸이 매 스텝 기록	사람의 키보드 = 행동	보상도 함께 기록

플레이 과정 ② 시연 기록

관측과 행동의 쌍이 파일로

① 사람이 플레이 | **② 시연 기록** | ③ 따라 하며 시작 | ④ 스스로 다듬기



게임에서 일어나는 일

- Play 를 멈추면 .demo 파일 생성
- 판 수 · 평균 보상 확인
- Record 를 끈다

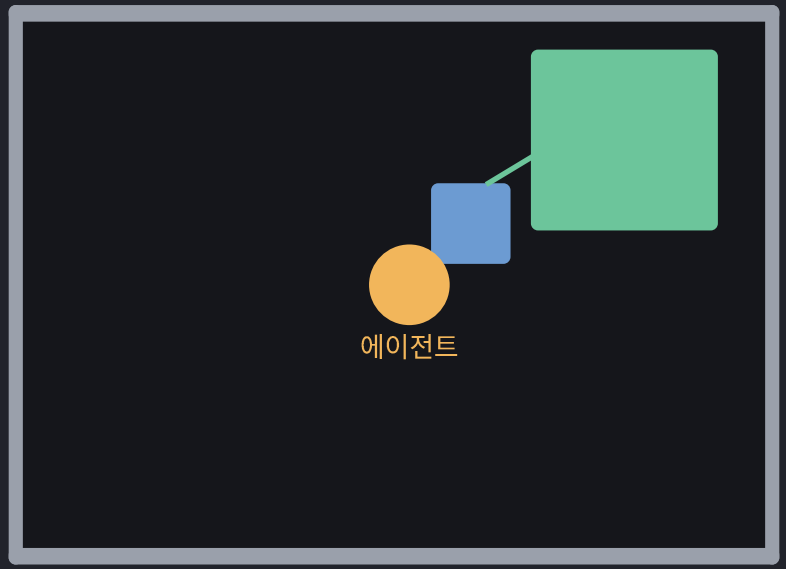
플레이어의 판단 "성공 판이 충분한가?"

관측	행동	보상
(관측, 행동) 쌍 수천 개	—	평균 보상 ≈ 1

플레이 과정 ③ 따라 하며 시작

BC — 사람의 선택을 흉내

① 사람이 플레이 | ② 시연 기록 | **③ 따라 하며 시작** | ④ 스스로 다듬기



게임에서 일어나는 일

- 학습 초반엔 시연을 따라 한다
- 첫 성공이 훨씬 빨리 온다
- 흉내 비중은 점점 줄인다

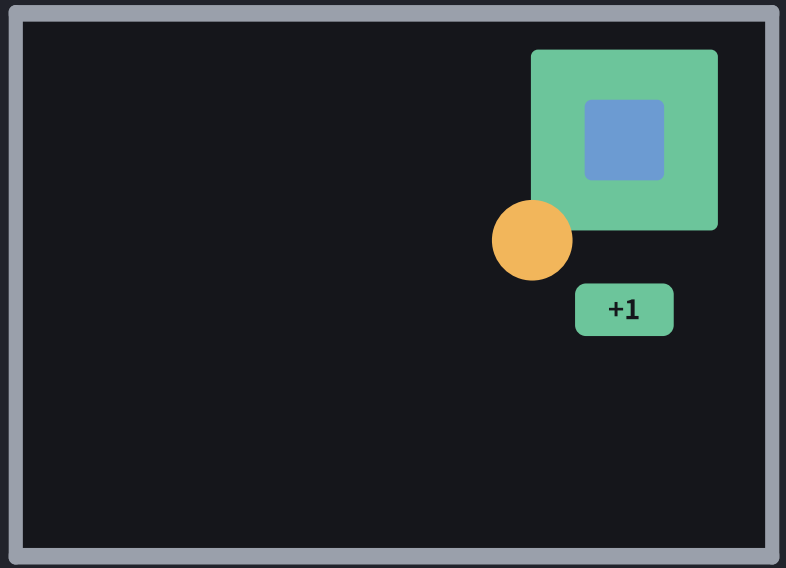
플레이어의 판단 "사람처럼 상자 뒤로 간다"

관측	행동	보상
관측 8칸	시연과 비슷한 행동	환경 보상 + 흉내 손실

플레이 과정 ④ 스스로 다듬기

PPO 가 시범보다 낫게 만든다

① 사람이 플레이 | ② 시연 기록 | ③ 따라 하며 시작 | **④ 스스로 다듬기**



게임에서 일어나는 일

- 흉내 비중이 줄고 보상이 주도
- 사람보다 빠른 길을 찾기도
- 골인 +1

플레이어의 판단 "시범에서 출발해 더 잘한다"

관측	행동	보상
관측 8칸	보상이 높은 쪽으로 다듬어짐	+1 — 골인

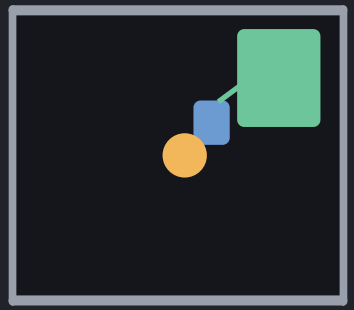
점수와 승패

판의 승패는 F 와 같다 — 이 프로젝트의 성과는 '얼마나 빨리 배우는가'



골인

- 상자가 골 안 → +1
- 시연 덕에 첫 성공이 빠르다



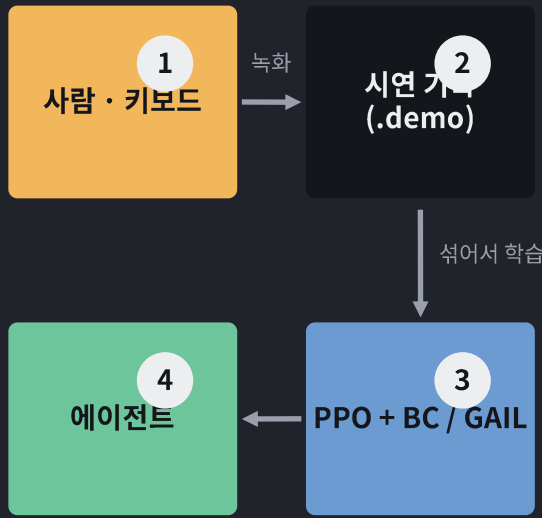
시간 초과

- 1500 스텝 안에 못 넣음
- 나쁜 시연은 나쁜 습관을 옮긴다

조건	판정 방법 (코드에서)	결과
골인	상자 중심이 골 칸 안	+1 · 판 끝
상자 진전	상자 ↔ 골 거리 감소	× 0.5, ±0.02 상한 (F 와 같음)
(BC · GAIL)	yaml 의 behavioral_cloning · gail	보상이 아니라 학습 신호 — 따로 실험

등장 요소

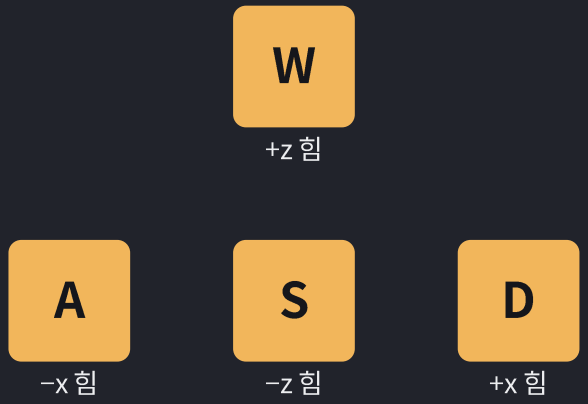
장면에 무엇을 두고, 무엇이 매 판 바뀌는가



#	오브젝트	역할	컴포넌트	매 판
1	사람 · 키보드	시연하는 사람	Heuristic (F 와 같은 키)	-
2	Demonstration Recorder	녹화기	Agent 오브젝트에 붙임	녹화 때만 켬
3	PPO + BC / GAIL	학습 설정	yaml — demo_path	실험마다 하나
4	Agent · Box · Goal	F 와 같은 장면	Rigidbody · Agent …	F 와 같음

사람 조작 (Heuristic)

학습 전에 사람이 먼저 플레이해 본다



왜 먼저 사람이 하나

이 프로젝트에서는 사람의 플레이가 곧 학습 데이터다. 일관되게 조작해야 따라 하기 쉽다

기록해 둘 것

녹화한 판 수 · 성공 판 수 · 평균 보상 (.demo 파일 Inspector 에서 확인)

게임 → 강화학습

게임의 각 요소가 강화학습의 무엇이 되는가

강화학습		이 게임에서
Agent	에이전트	공 (F 와 같음)
Environment	환경	벽 · 상자 · 골 (F 와 같음)
Observation	관측	F 와 같은 8칸 — 녹화 때와 같아야 한다
Action	행동	F 와 같음 — 사람의 키 입력이 시연 행동
Reward	보상	F 와 같음 + (BC 손실 또는 GAIL 보상)
Episode	에피소드	F 와 같음



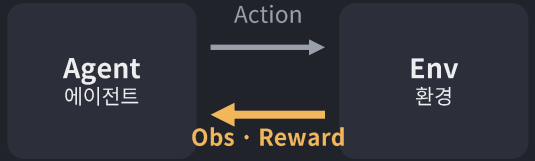
결정할 때마다 관측을 보고 행동을 고르고, 그 결과로 보상을 받는다

관측 설계 Observation

에이전트가 결정할 때마다 보는 숫자

예시 설계 — 바꿔 보고 기록 **= 8칸**

항목	칸	왜 필요한가
상자 – 공 · 골 – 상자	4	F 와 같음
공 · 상자 속도	4	F 와 같음



환경 → 에이전트. 칸 수를 Behavior Parameters 의 Space Size 와 맞춘다

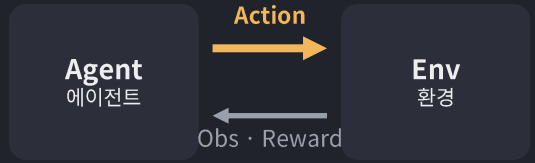
관측을 바꾸면 시연을 다시 녹화해야 한다 — 녹화 전에 관측을 굳힌다

행동 설계 Action

에이전트가 결정할 때마다 고르는 값

예시 설계 — 바꿔 보고 기록 **연속 2**

번호	값	하는 일	키보드
0	−1 ~ +1	x 방향 힘 × 10	A / D
1	−1 ~ +1	z 방향 힘 × 10	W / S

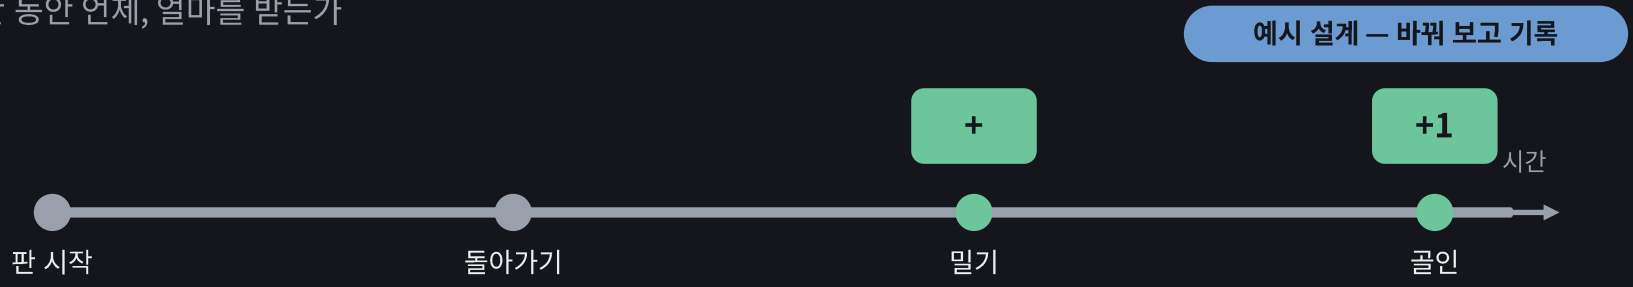


에이전트 → 환경. 행동 순서 = 키보드 순서로 맞추면 Heuristic 이 쉽다

잘 만든 Heuristic 이 곧 좋은 시연 녹화기다 — 키 입력이 행동과 같은 형태인가

보상 설계 Reward

한 판 동안 언제, 얼마를 받는가



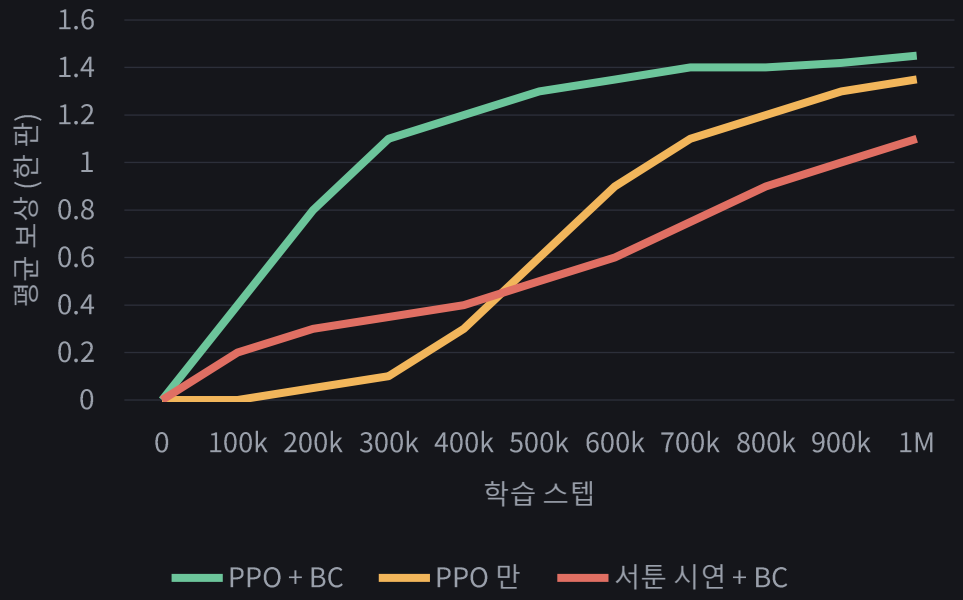
사건	보상	판은?
환경 보상 (F 와 같음)	**진전 + 골인 +1**	늘 켜 둠
BC (따라 하기)	**strength 0.5**	처음 5만 스텝만
GAIL (닮으면 보상)	**strength 0.1**	BC 와 따로 실험

한 번에 하나씩 — PPO 만 / +BC / +GAIL 을 따로 학습해 비교한다

보상이 만드는 플레이

보상 설계에 따라 어떤 플레이가 높은 점수를 받는가

예시 곡선 — 실측 아님



이 보상이 유도하는 행동

시연이 출발점, 환경 보상이 결승점 → 사람의 방식으로 시작해 보상으로 다듬기

넣지 않은 보상과 이유

GAIL strength 를 환경 보상보다 크게 — 골에 넣기보다 '사람처럼 보이기'를 우선한다

에피소드 설계 Episode

한 판은 언제 시작하고, 무엇이 바뀌고, 언제 끝나는가

녹화 (Heuristic Only)

Record 켜기
성공 판 약 20개
Play 멈춤 → .demo

›

학습 (Default)

Record 끄기
yaml 에 demo_path
PPO / +BC / +GAIL

›

판 (F 와 같음)

시작: 무작위 배치
골인 +1 · 진전 보상
Max Step 1500

녹화를 켠 채 학습하면 .demo 가 계속 커진다 — 녹화가 끝나면 Record 를 끈다

학습 환경 구성

영역을 복제해 한 두뇌가 동시에 여러 판을 경험한다



같은 Behavior Name 의 영역 9개 → 한 두뇌

설정	예시 값	뜻
Behavior Name	BoxPusher	F 와 같게
demo_path	Demos/push_good.demo	녹화 폴더 경로
behavioral_cloning	strength 0.5 · steps 5만	초반만 따라 하기
gail	strength 0.1	따로 실험
max_steps (yaml)	1,000,000	세 실험 같은 값
예상 시간	40~90분 × 3	예상치 — 직접 잰다

개발 단계

단계마다 만들 것과, 다음으로 넘어가는 기준

1단계 바탕 과제 준비

만들 것

F 상자 밀기 완성
Heuristic 점검
관측 굳히기

완료 기준

키보드로 골인 안정적

›

2단계 시연 녹화

만들 것

Recorder 붙이기
성공 20판 녹화
Record 끄기

완료 기준

.demo · 평균 보상 ≈ 1

›

3단계 세 가지 학습

만들 것

PPO 만
+BC · +GAIL
같은 스텝 수

완료 기준

세 그래프 저장

›

4단계 비교 · 완성

만들 것

첫 성공 스텝 비교
(선택) 서툰 시연
시연 영상

완료 기준

비교표 · 시연 영상

예상 문제와 대응

학습이 엉뚱하게 갈 때 먼저 볼 곳

학습 시작 시 demo 에러	원인	관측 · 행동 크기가 녹화 때와 다름
	대응	관측을 바꿨으면 다시 녹화
사람 수준에서 멈춘다	원인	BC 비중이 너무 오래 큼
	대응	behavioral_cloning steps 를 줄인다
흉내 점수만 오른다	원인	GAIL 이 환경 보상보다 큼
	대응	gail strength 0.1 이하로

한 번에 하나만 바꾸고, 바꾼 이유와 결과를 숫자로 기록한다